

# 融合 Q-learning 的低空无人机集群通信链路自适应调度研究

杨锦涛, 王昕

(辽宁工程技术大学电子与信息工程学院, 葫芦岛 125000)

**摘要:** 随着低空经济的快速发展, 无人机在应急通信、环境监测和物流运输等领域得到广泛应用。低空无人机自组网由于具有节点高速移动、网络拓扑动态变化频繁以及通信链路不稳定等特点, 传统自组网路由协议在复杂动态环境中的性能受到一定限制。为提高低空无人机网络的通信效率与资源利用率, 本文提出一种基于 Q-learning 的低空无人机自组网资源调度与路由优化方法。首先构建低空无人机自组网系统模型, 分析节点通信与资源分配特性; 其次将 Q-learning 算法引入路由决策过程, 通过构建包含节点剩余能量、节点间距离以及队列长度等因素的状态空间, 并设计综合奖励函数, 实现对下一跳节点的智能选择与网络资源的动态调度; 最后通过仿真实验对所提出算法进行性能评估, 并与传统 AODV 和 OLSR 路由协议进行对比分析。仿真结果表明, 该方法在数据包投递率、平均时延和能量利用效率等指标上优于 AODV 和 OLSR 协议, 适用于高动态低空无人机自组网场景。

**关键词:** 低空无人机网络; 自组网; Q-learning; 资源调度; 路由优化

**中图分类号:** TN915.04

## Research on Adaptive Scheduling of Low altitude UAV Cluster Communication Link Integrating Q-learning

Yang Jintao, Wang Xin

(School of Electronic and Information Engineering, Liaoning Technical University, Huludao 125000)

**Abstract:** With the rapid development of the low-altitude economy, unmanned aerial vehicles (UAVs) have been widely applied in emergency communication, environmental monitoring, and logistics transportation. Due to the characteristics of high-speed node movement, frequent dynamic changes in network topology, and unstable communication links, the performance of traditional ad hoc network routing protocols is limited in complex and dynamic environments. To improve the communication efficiency and resource utilization of low-altitude UAV networks, this paper proposes a resource scheduling and routing optimization method for low-altitude UAV ad hoc networks based on Q-learning. Firstly, a low-altitude UAV ad hoc network system model is constructed, and the communication and resource allocation characteristics of nodes are analyzed. Secondly, the Q-learning algorithm is introduced into the routing decision process. By constructing a state space that includes factors such as the remaining energy of nodes, the distance between nodes, and the queue length, and designing a comprehensive reward function, the intelligent selection of the next-hop node and the dynamic scheduling of network resources are achieved. Finally, the performance of the proposed algorithm is evaluated through simulation experiments and compared with traditional AODV and OLSR routing protocols. The experimental results show that the proposed algorithm exhibits better performance in terms of packet delivery ratio, average delay, and network energy utilization, effectively enhancing the overall communication efficiency of low-altitude UAV ad hoc networks. The research results can provide certain references for intelligent routing and resource management in low-altitude UAV networks.

**Keywords:** Low-altitude unmanned aerial vehicle (UAV) network; Ad hoc network; Q-learning; Resource scheduling; Routing optimization

**作者简介:** 杨锦涛 (2006-), 男

**通信联系人:** 王昕 (1989-), 女, 讲师, 主要研究领域包括信息与信号处理、大数据分析。主持教育部产学合作协同育人项目 1 项, 主持教育部供需对接就业育人项目 1 项. E-mail: 15904291180@139.com

## 0 引言

随着信息技术与航空技术的发展,无人机在多领域广泛应用,低空经济推动下的无人机集群协同作业催生了低空无人机自组网(FANET),其可在通信基础设施薄弱或受损环境中实现灵活高效信息传输。与传统地面移动自组网相比,FANET存在节点移动快、拓扑多变、链路不稳定及节点资源受限等特点,传统路由协议难以适配,导致路由失效、数据包丢失等问题,因此研究适配的智能路由与资源调度方法至关重要。国内外学者围绕无人机自组网路由与资源管理开展大量研究,传统AODV、OLSR协议因适配性不足难以满足需求,后续出现的地理位置感知路由、分簇管理及资源分配相关研究虽有改进,但仍有局限。近年来,基于强化学习的智能路由成为热点<sup>[1]</sup>,Q-learning等方法被应用于路由决策,但现有研究多侧重路由选择,忽视路由与资源调度的协同优化,存在资源利用效率低、性能不稳定等问题。针对上述问题,本文提出基于Q-learning的低空无人机自组网资源调度与路由优化方法,先构建系统模型分析节点特性与资源约束,再将Q-learning引入路由决策,设计合理状态空间与奖励函数实现下一跳智能选择,结合资源调度机制实现协同优化,最后通过MATLAB仿真验证,结果表明该方法在数据包投递率、通信时延及能量利用效率上优势显著,可提升网络整体性能并提供研究参考。

## 1 无人机自组网系统模型

### 1.1 无人机网络模型

低空无人机自组网由多架无人机节点通过无线通信链路构成,具有分布式、自组织和高度动态等特点。与传统地面移动自组网相比,无人机节点在三维空间中高速移动,网络拓扑结构随时间不断变化,因此需要构建合理的网络模型来描述节点之间的通信关系。

本文考虑由N个无人机节点组成的低空自组网系统,节点在给定的三维空间区域内飞行,并通过无线通信方式进行信息交互。网络中每个节点既可以作为数据源节点,也可以作为中继节点参与多跳数据转发。为简化分析,假设所有无人机节点具有相同的通信和处理能力,并能够实时获取自身位置信息。

设无人机节点*i*和节点*j*在时刻*t*的空间位置分别为 $(x_i(t), y_i(t), z_i(t))$ 和 $(x_j(t), y_j(t), z_j(t))$ ,则两节点之间的欧氏距离为:

$$d_{ij}(t) = \sqrt{(x_i(t) - x_j(t))^2 + (y_i(t) - y_j(t))^2 + (z_i(t) - z_j(t))^2}$$

假设每个节点具有固定的通信半径*R*,当 $d_{ij}(t) \leq R$ 时,节点*i*与节点*j*之间可以建立直接通信链路;否则需要通过其他节点进行多跳转发。节点通过周期性广播控制信息获取邻居节点状态,并维护邻居节点集合:

$$N_i = \{j | d_{ij}(t) \leq R, i \neq j\}$$

在网络拓扑不断变化的情况下，邻居节点集合随时间动态更新，因此路由算法需要具备良好的自适应能力，以保证通信的连续性和稳定性[2]。

## 1.2 通信模型

在低空无人机自组网中，节点之间通过无线信道进行数据传输，其通信性能受节点间距离、信道衰减以及网络负载等因素影响。由于无人机网络具有较强的动态性，通信链路质量可能随时间发生变化[3]，因此需要建立通信模型对链路传输能力进行描述。

本文采用路径损耗模型描述信号在传播过程中的衰减特性。设节点  $i$  的发射功率为  $P_t$ ，节点  $j$  接收到的信号功率为  $P_r$ ，则有：
$$P_r = P_t \left( \frac{d_0}{d_{ij}} \right)^\alpha$$

其中， $d_{ij}$  为节点间距离， $d_0$  为参考距离， $\alpha$  为路径损耗指数。

为衡量通信链路的传输能力，本文采用信噪比（SNR）作为链路质量指标。设信道带宽为  $B$ ，根据香农定理，链路的最大理论传输速率可表示为：

$$C = B \log_2(1 + \text{SNR})$$

当节点间距离较近、信噪比较高时，链路可支持较高的数据传输速率；反之，链路质量下降，传输性能受限。此外，在多节点同时通信的情况下，信道竞争和网络负载增加可能导致排队时延和丢包率上升。因此，在路由与资源调度过程中需要综合考虑链路质量和节点负载情况。

## 1.3 资源模型

在低空无人机自组网中，节点在完成通信任务的同时还受到能量、带宽和缓存等资源约束[4]。为合理描述网络资源特性，本文从节点能量资源、带宽资源以及队列资源三个方面建立资源模型。

### （1）节点能量资源

无人机节点依赖电池供电，在数据发送、接收和转发过程中均会消耗能量。

设节点的初始能量为  $E_i^0$ ，剩余能量为  $E_i$ ，则其能量消耗可表示为：

$$E_i = E_i^0 - (E_{tx} + E_{rx})$$

当节点剩余能量较低时，其持续参与数据转发将影响网络稳定性，因此在路由决策中需要考虑节点能量状态，以实现负载均衡并延长网络生命周期[5]。

### （2）带宽资源

无人机自组网中各节点共享有限的无线信道资源。设网络总带宽为  $B$ ，节点  $i$  占用的带宽为  $B_i$ ，则需满足：

$$\sum_{i=1}^N B_i \leq B$$

合理的带宽分配有助于减少通信冲突，提高网络传输效率。

### 110 (3) 队列资源

节点发送的数据包通常需在队列中等待转发。当队列长度过大时，容易导致排队时延增加甚至数据包丢失。设节点  $i$  的队列长度为  $Q_i$ ，则在路由选择过程中应尽量避免继续向队列负载较高的节点转发数据，以提高网络整体性能。

综上所述，节点能量、带宽和队列状态等资源因素对低空无人机自组网通信性能具有重要影响。本文在后续基于 Q-learning 的路由优化算法设计中，将综合考虑上述资源信息，通过构建合理的状态空间和奖励函数，实现资源调度与路由选择的协同优化。

## 115 2 Q-learning 算法原理

强化学习是一种通过智能体与环境不断交互来学习最优决策策略的机器学习方法。智能体通过感知环境状态并采取相应动作，根据环境反馈的奖励信息不断调整自身策略，从而逐步获得最优决策方案。由于强化学习不依赖于环境的精确数学模型，具有较强的自适应能力，因此在通信网络优化、资源调度和路径规划等领域得到了广泛应用。

在强化学习方法中，Q-learning 是一种典型的无模型学习算法。该算法通过构建状态—动作价值函数，对不同决策行为进行长期收益评估，具有实现简单、收敛性好以及适应动态环境能力强等优点，适用于低空无人机自组网中复杂多变的路由决策问题。本章对强化学习的基本概念、Q-learning 算法原理以及动作选择策略进行简要介绍，为后续算法设计提供理论基础<sup>[6]</sup>。

### 125 2.1 强化学习基本概念

强化学习问题通常可建模为马尔可夫决策过程（Markov Decision Process, MDP），主要由智能体、环境、状态、动作和奖励等要素组成。在无人机自组网环境中，每个无人机节点可视为一个智能体，其通过感知网络状态并选择转发动作，实现数据包的动态路由决策。

状态用于描述系统在某一时刻的环境信息，在无人机网络中通常包括节点剩余能量、节点间距离、链路质量以及节点队列状态等；动作表示智能体在当前状态下可采取的决策行为，如选择某一邻居节点作为下一跳节点；奖励用于评价智能体所采取动作的效果，若该动作有助于提升网络性能，则给予正奖励，否则给予负奖励。通过不断试探和更新，智能体能够逐渐学习到最优策略。

## 2.2 Q-learning 算法原理

Q-learning 是一种基于价值函数的强化学习算法，其核心思想是通过不断更新状态—动作价值函数  $Q(s, a)$ ，评估在状态  $s$  下采取动作  $a$  所能获得的长期回报。状态—动作价值函数的更新公式为：

$$Q(s, a) = Q(s, a) + \alpha[\beta + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$

其中， $Q(s, a)$  表示在状态  $s$  下采取动作  $a$  的价值； $\alpha$  为学习率，用于控制新信息对原有  $Q$  值的影响程度； $\beta$  为即时奖励； $\gamma$  为折扣因子，用于衡量未来奖励的重要性； $s'$  为执行动作后的下一状态。

在算法运行过程中，智能体根据当前状态选择动作并执行，随后接收环境反馈并更新  $Q$  值。随着学习过程的不断进行， $Q$  值逐渐收敛，智能体能够获得较优的决策策略。

## 2.3 $\epsilon$ -greedy 动作选择策略

在强化学习过程中，智能体需要在探索新策略和利用已有最优策略之间进行权衡。为实现探索与利用的平衡，Q-learning 算法通常采用  $\epsilon$ -greedy 动作选择策略。该策略在大多数情况下选择当前  $Q$  值最大的动作，同时以一定概率随机选择其他动作，从而避免陷入局部最优。

其动作选择规则可表示为：

$$a = \begin{cases} \text{random action, with probability} & \epsilon \\ \arg \max Q(s, a), \text{ with probability} & 1 - \epsilon \end{cases}$$

其中， $\epsilon$  为探索概率。在实际应用中，通常随着学习过程的推进逐渐减小  $\epsilon$ ，以提高算法的收敛速度。

综上所述，Q-learning 算法通过状态—动作价值函数更新与合理的动作选择策略，使智能体能够在动态环境中逐步学习到较优决策方案。该算法具有良好的自适应性，适用于低空无人机自组网中动态路由决策问题。下一章将在此基础上设计基于 Q-learning 的资源调度与路由优化算法

## 3 基于 Q-learning 的资源调度与路由优化算法

在低空无人机自组网环境中，由于节点高速移动、网络拓扑频繁变化以及通信资源受限，传统路由算法难以在动态环境下保持稳定性能。为此，本文在前述系统模型和 Q-learning 算法原理的基础上，提出一种基于 Q-learning 的资源调度与路由优化算法。该算法通过引入强化学习机制，使无人机节点能够根据实时网络状态自主学习路由策略，并结合节点资源信息实现资源调度与路由选择的协同优化，从而提升网络整体通信性能。



## 165 3.1 算法设计思路

在无人机自组网中,数据通常通过多跳方式从源节点传输至目的节点。由于节点移动性较高,单纯依据最短路径进行路由选择容易导致链路不稳定,增加路由重建开销;同时,部分节点长期承担大量转发任务还会造成能量消耗不均,影响网络生存时间。

170 针对上述问题,本文引入 Q-learning 算法,使无人机节点能够根据网络状态动态调整路由决策。在数据转发过程中,节点依据当前状态信息从邻居节点中选择合适的下一跳节点,并根据传输结果获得奖励,通过不断更新 Q 值逐步学习最优策略。同时,在状态空间和奖励函数设计中引入节点能量、节点距离和队列状态等资源信息,使路由决策在保证通信效率的同时兼顾资源利用,实现资源调度与路由优化的协同设计。

## 175 3.2 状态空间设计

在 Q-learning 算法中,状态空间用于刻画网络在某一时刻的运行状态。为充分反映无人机网络的通信特性和资源约束,本文选取邻居节点的剩余能量、节点间距离以及队列长度作为状态变量。

设节点  $i$  为当前节点,其邻居节点为  $j$ ,系统状态可表示为:

$$s = (E_j, d_{ij}, Q_j)$$

180 其中,  $E_j$  表示邻居节点  $j$  的剩余能量,  $d_{ij}$  表示节点  $i$  与节点  $j$  之间的距离,  $Q_j$  表示节点  $j$  的数据队列长度。上述状态能够综合反映节点资源状况和链路质量,为路由决策提供依据<sup>[7]</sup>。

## 185 3.3 动作空间设计

在无人机自组网路由问题中,节点的决策行为主要体现在下一跳节点的选择上。本文将动作定义为从邻居节点集合中选择一个节点作为数据转发的下一跳。

设节点  $i$  的邻居节点集合为:

$$N_i = \{j | d_{ij} \leq R\}$$

其中,  $R$  为节点通信半径。则节点  $i$  的动作空间可表示为:

$$A = \{a_1, a_2, \dots, a_k\}$$

190 其中,  $k$  为节点  $i$  的邻居节点数量。节点通过比较不同动作对应的 Q 值,选择价值最大的动作作为当前转发决策。

## 3.4 奖励函数设计

奖励函数是强化学习算法设计的关键,其直接影响算法的学习效果。为实现路由优化与资源调度的协同目标,本文在奖励函数中综合考虑节点能量、节点间距离和通信时延等因素。

设节点  $i$  选择节点  $j$  作为下一跳节点,则即时奖励函数定义为:

$$195 \quad R = w_1 \frac{E_j}{E_{\max}} - w_2 \frac{d_{ij}}{R} + w_3 \frac{1}{\text{Delay}}$$

其中,  $E_{\max}$  表示节点最大能量, Delay 表示数据传输时延,  $w_1$ 、 $w_2$ 、 $w_3$  为权重系数。


该奖励函数能够鼓励节点优先选择能量充足、距离较近且时延较小的节点作为下一跳，从而提升数据传输效率并实现网络负载均衡<sup>[8]</sup>。

### 3.5 资源调度机制

200       在路由决策过程中，本文进一步引入资源调度机制以提升网络资源利用效率。节点在选择下一跳节点时，会综合考虑邻居节点的剩余能量和队列状态。当某一节点队列长度过大或能量过低时，其被选为下一跳节点的概率将降低，从而避免网络负载集中和节点过早失效。

205       结合 Q-learning 的学习机制，节点能够在不断交互过程中逐步学习到合理的资源调度策略，使数据流量在网络中更加均衡地分布，提高网络稳定性和生存时间。

## 3.6 算法流程





4 基于 Q-learning 的资源调度与路由优化算法

4.1 仿真环境

210 为验证本文提出的基于 Q-learning 的低空无人机自组网资源调度与路由优化算法的有效性，本文在 MATLAB 平台下构建无人机自组网仿真场景，并与传统路由协议进行对比分析。

215 在仿真场景中，无人机节点在给定区域内随机分布并进行移动，节点之间通过无线链路进行通信。当节点间距离小于通信半径时可建立通信连接，数据包通过多跳方式从源节点传输至目的节点。仿真过程中综合考虑节点移动、链路变化及网络负载等因素，以模拟实际低空无人机网络环境。

220 仿真区域设置为 1000×1000m 的二维平面区域，网络中部署 30 个无人机节点，节点初始位置随机生成，并按照随机移动模型运动。每个节点具有固定通信半径，网络数据流量随机产生。主要仿真参数设置如表 1 所示。

表 1 仿真参数设置

Tab. 1 Simulation parameter settings

| 参数名称            | 参数值        |
|-----------------|------------|
| 仿真区域            | 1000*1000m |
| 节点数量            | 30         |
| 通信半径            | 200m       |
| 信道带宽            | 2MHz       |
| 节点初始能量          | 100J       |
| 仿真时间            | 100s       |
| 学习率 $\alpha$    | 0.1        |
| 折扣因子 $\gamma$   | 0.9        |
| 探索概率 $\epsilon$ | 0.1        |

在上述仿真环境下，通过多次独立实验获取不同算法的性能数据，并对实验结果进行统计分析，以保证仿真结果的可靠性和客观性。

225 4.2 对比算法

为客观评估本文算法的性能优势，选取两种典型自组网路由协议作为对比算法，分别为 AODV 和 OLSR。

230 AODV 是一种按需路由协议，仅在需要通信时才进行路由发现，能够在一定程度上降低控制开销。但在节点高速移动的无人机网络中，其路由路径容易失效，需要频繁进行路由重建，从而导致时延和控制开销增加。

OLSR 是一种主动式路由协议,通过周期性交换拓扑信息维护路由表,并利用多点中继机制减少广播开销。然而,在拓扑变化频繁的无人机自组网环境中,持续更新拓扑信息会带来较大的控制负载,影响网络整体性能。

本文提出的基于 Q-learning 的资源调度与路由优化算法,通过强化学习机制实现路由决策的动态优化。该算法能够综合利用节点剩余能量、节点距离和队列状态等信息,自主学习最优转发策略,并通过资源调度机制实现网络负载均衡,从而提升网络通信性能。

### 4.3 性能指标

为全面评估不同路由算法的性能,本文选取数据包投递率、平均端到端时延、网络吞吐量以及能量消耗四个典型指标进行性能分析。

数据包投递率(PDR)用于衡量网络通信的可靠性,其定义为成功到达目的节点的数据包数量与源节点发送数据包总数量之比。平均端到端时延用于衡量数据传输效率,表示数据包从发送到成功接收所经历的平均时间。网络吞吐量用于反映单位时间内网络成功传输的数据量。能量消耗则表示网络在通信过程中所消耗的总能量,是评价网络生存能力的重要指标。

通过上述性能指标,可以从可靠性、时延、传输能力以及资源利用等多个角度对不同路由算法的性能进行综合比较。

### 4.4 仿真结果分析

为验证本文提出算法的性能优势,在 MATLAB 仿真环境下,通过改变网络中无人机节点数量,对不同算法在平均端到端时延、网络吞吐量、数据包投递率和能量消耗等指标上的表现进行了对比分析,仿真结果如图 5-1~图 5-4 所示。

#### (1) 平均端到端时延分析




图 4-1 平均端到端时延对比  
Fig. 4-1 Delay Comparison

图 4-1 给出了不同节点数量条件下，各算法的平均端到端时延对比结果。可以看出，随着无人机节点数量的增加，网络规模扩大，数据包需要经过更多中继节点，同时网络负载上升，导致所有算法的平均时延均呈现上升趋势。

相比 AODV 和 OLSR，本文提出的基于 Q-learning 的路由优化算法在不同节点规模下均保持较低的平均端到端时延，且在节点数量较大时优势更加明显。这是由于该算法能够根据实时网络状态动态选择链路质量较好、负载较轻的节点作为下一跳，从而减少无效转发和频繁路由重建带来的额外时延。

(2) 网络吞吐量分析




图 4-2 网络吞吐量对比

Fig. 4-2 Throughput Comparison

图 4-2 展示了不同节点数量条件下，各算法的网络吞吐量对比结果。随着节点数量增加，网络中可用路径增多，整体吞吐量呈上升趋势。

可以观察到，本文算法在所有节点规模下均获得了较高的网络吞吐量，并在节点数量较多时表现出明显优势。这表明 Q-learning 算法能够通过不断学习网络环境，自适应调整路由策略，使网络流量在不同节点之间更加均衡分布，从而有效提高链路利用率和整体数据传输能力。

(3) 数据包投递率分析




图 4-3 数据包投递率对比

Fig. 4-3 PDR Comparison

图 4-3 给出了不同节点数量条件下, 各算法的数据包投递率对比结果。随着节点数量增加, 网络连通性增强, 各算法的投递率整体呈上升趋势, 但不同算法之间仍存在明显差异。

本文提出的 Q-learning 路由优化算法在各节点规模下均取得了最高的数据包投递率, 尤其在节点数量较多时优势更为突出。这主要得益于算法在路由选择过程中综合考虑了节点能量、距离和队列状态, 有效规避链路不稳定或资源受限节点, 从而降低数据包丢失概率。

#### (4) 能量消耗分析




图 4-4 能量消耗对比

Fig. 4-2 Energy Comparison

图 4-4 给出了不同节点数量条件下, 各算法的能量消耗对比结果。随着网络规模扩大, 参与数据转发的节点数量增加, 网络整体能量消耗随之上升。

相比对比算法, 本文提出的 Q-learning 路由优化算法在能量消耗方面表现出明显优势。该算法通过在路由决策中引入节点剩余能量信息, 避免部分节点长期承担大量转发任务, 实现了网络负载均衡, 从而有效降低了整体能量消耗并延长网络运行时间。

#### (5) 综合分析

综合图 4-1~图 4-4 的仿真结果可以看出, 本文提出的基于 Q-learning 的低空无人机自组网资源调度与路由优化算法在平均端到端时延、网络吞吐量、数据包投递率以及能量消耗等关键指标上均优于传统路由协议。该算法能够根据网络动态变化自适应调整路由策略, 并在路由决策过程中兼顾通信性能与资源利用效率, 验证了其在低空无人机自组网环境中的有效性和可行性。

## 5 结论

针对低空无人机自组网中节点高速移动、网络拓扑频繁变化以及通信资源受限等问题, 本文围绕无人机网络路由稳定性与资源利用效率展开研究, 提出了一种基于 Q-learning 的低空无人机自组网资源调度与路由优化方法。该方法将强化学习引入无人机网络路由决策过程, 使节点能够根据网络状态自适应地学习最优转发策略, 从而提升网络整体通信性能。

本文首先构建了低空无人机自组网的网络模型、通信模型和资源模型, 对无人机节点的通信特性及资源约束进行了分析。在此基础上, 将路由选择问题建模为强化学习过程, 设

305 计了包含节点剩余能量、节点间距离和队列状态等信息的状态空间，并构建了综合考虑通信性能与资源消耗的奖励函数，实现了资源调度与路由优化的协同设计。通过 Q-learning 的持续学习与更新，节点能够逐步形成更加合理的路由决策策略。

310 在 MATLAB 仿真环境下，对所提出算法进行了性能验证，并与传统路由协议进行了对比分析。仿真结果表明，本文提出的基于 Q-learning 的路由优化算法在平均端到端时延、网络吞吐量、数据包投递率以及能量消耗等关键性能指标上均表现出较好的综合性能。尤其在网络规模较大、拓扑变化频繁的场景下，该算法能够有效降低通信时延、提高数据传输可靠性，并实现网络能量的均衡利用，验证了算法的有效性和可行性。

315 尽管本文所提出的方法在仿真环境中取得了较好的性能，但仍存在一定的改进空间。未来的研究可进一步考虑更加复杂的无人机移动模型和信道环境，引入深度强化学习方法以提升算法在大规模网络中的学习能力和泛化性能，并结合实际应用场景对算法进行优化与验证，从而进一步提高低空无人机自组网的实用性和可靠性。

#### [参考文献] (References)

- 320 [1] 祝源. 基于机器学习的无人机组网技术研究[D]. 成都: 电子科技大学, 2024.
- [2] 梁五建. 基于消息摆渡的无人集群网络路由技术研究[D]. 北京: 北京邮电大学, 2024.
- [3] 刘文睿. 面向无人机网络的感知通信融合路由技术研究[D]. 北京: 北京邮电大学, 2023.
- [4] 张昕婷. 面向电磁频谱侦察的无人机集群分簇机制与装订路由算法研究[D]. 南京: 南京航空航天大学, 2023.
- [5] 易秀明. 无人机集群智能路由技术研究[D]. 北京: 北京邮电大学, 2025.
- 325 [6] 苏灏. 基于自适应拓扑感知和强化学习的无人机自组网路由协议研究[D]. 西安: 西安电子科技大学, 2024.
- [7] 谭周正, 范琅, 李宇峰, 章小宁. 基于强化学习的无人机网络自适应 QoS 路由算法[J]. 计算机应用研究, 2025, 42 (4): 1177-1184.
- [8] 郭靖. 基于强化学习的无人机自组网路由算法研究[D]. 南京: 东南大学, 2023.